**Universidade Presbiteriana Mackenzie**
**Tecnólogo em Banco de Dados 2º Semestre**

# Projeto Aplicado I

**Aluno(a): Giovanna Andrade de Sousa RA: 10764499**
**Aluno(a): Sabrina Sales Machado RA: 10764045**
**Aluno(a): Távi Braz Silva RA: 10780868**

# Sumário

1. Objetivos do projeto: ..... 3
2. Dataset ..... 3
3. Dicionário de dados: ..... 4
4. Cronograma e Divisão de Responsabilidades ..... 9
5. Bibliografia ..... 12

# 1. Objetivos do projeto:

Representando a maior estrutura educacional do país, a Secretaria da Educação do Estado de São Paulo abrange cerca de 5,3 mil unidades escolares, atendendo por volta de 3,5 milhões de estudantes. Seu corpo funcional conta com 234 mil integrantes distribuídos entre o Quadro do Magistério, Apoio Escolar e Secretaria, incluindo 190 mil docentes e 5 mil gestores escolares. Toda essa estrutura está organizada sob 91 Diretorias Regionais de Ensino, subdivididas em 15 Polos Regionais. Sendo um órgão público da cidade de São Paulo, que oferece educação gratuita para a população, lidamos principalmente com o objetivo 4 da ODS da ONU (Objetivos de Desenvolvimento Sustentável), que é assegurar a educação inclusiva e equitativa e de qualidade, e promover oportunidades de aprendizagem ao longo da vida para todas e todos.

O dataset escolhido apresenta informações de matrícula de alunos matriculados em São Paulo, com dados geográficos, etnográficos, de adesão a projetos de assistência social, necessidade e efetiva assistência a pessoas com deficiências e de rendimento escolar.

O objetivo principal é analisar o rendimento escolar ao longo dos últimos 5 anos, ao mesmo tempo em que se entende as diferentes segmentações por diferentes marcadores sociais. Existe algum grupo que tenha performado pior ao longo dos anos? Os dados nos permitem entender, mesmo que de maneira superficial, motivos para isso? Acima de tudo, quais recomendações podemos fornecer para retomar o desempenho desses e dos próximos alunos com perfil parecido? Essas são as perguntas principais a serem respondidas ao longo do desenvolvimento da disciplina.

# 2. Dataset

Os dados originais podem ser encontrados em Dataset Dados de Matrícula (https://dados.educacao.sp.gov.br/dataset/microdados-de-matricula-sp), e estão disponíveis entre os anos de 2004 e 2026. Os arquivos são extensos em número de linhas e colunas, mas nosso recorte de 5 anos e claros objetivos de análise possibilitam um trabalho mais efetivo e que responda às perguntas iniciais.

Um dos campos principais deste dataset é o rendimento, e ele está vazio para alguns alunos. O número de vazios no geral pode ser contornado fazendo segmentações com dados demográficos, como idade, série ou região da escola, mas a disponibilidade de dados para representar uma segmentação específica é algo que teremos em mente ao longo do projeto, por exemplo, temos o mesmo número de dados de dados sobre rendimento de crianças negras e brancas, ou de meninos e meninas, ou de rendas distintas, e até onde podemos os comparar.

## 3. Dicionário de dados:

| Nome do Campo | Descrição do Campo | Tipo do Dado |
|---|---|---|
| CD_ALUNO | Código do Aluno | Numérico Inteiro |
| CD_ESCOLA | Código da Escola | Numérico Inteiro |
| DTNASC | Data de nascimento do aluno, no formato YYYYMM | Alfanumérico |
| SEXO | Sexo do aluno (M ou F) | Texto |
| RENDIMENTO | Código de rendimento do aluno : 1 Aprovado ; 2 Progressão Parcial; 3 Retido por Frequência Insuficiente; 4 Retido por Rendimento Insuficiente; 5 Retido Parcialmente; 6 Aprovado Parcialmente; 8 Curso em andamento | Numérico inteiro |
| DEF1 | Campo de deficiência do aluno, caso haja. | Numérico inteiro |
| DEF2 | Campo de deficiência do aluno, caso haja. | Numérico inteiro |
| DEF3 | Campo de deficiência do aluno, caso haja. | Numérico inteiro |
| DEF4 | Campo de deficiência do aluno, caso haja. | Numérico inteiro |
| DEF5 | Campo de deficiência do aluno, caso haja. | Numérico inteiro |

| | | |
|---|---|---|
| DEF6 | Campo de deficiência do aluno, caso haja. | Numérico inteiro |
| DEF7 | Campo de deficiência do aluno, caso haja. | Numérico inteiro |
| DEF8 | Campo de deficiência do aluno, caso haja. | Numérico inteiro |
| DEF9 | Campo de deficiência do aluno, caso haja. | Numérico inteiro |
| DEF10 | Campo de deficiência do aluno, caso haja. | Numérico inteiro |
| CORRACA | Cor/raça autodeclarada do aluno : 1 Branca; 2 Preta; 3 Parda; 4 Amarela; 5 Indigena; 6 Nao Declarada | Numérico inteiro |
| BAIRRO | Bairro onde o aluno reside | Texto |
| CEP | CEP do aluno | Numérico inteiro |
| CIDADE | Cidade de residência do aluno | Texto |
| SIGLA_END_UF | Sigla da UF do endereço do aluno | Texto |
| END_ZONA | Zona do endereço do aluno: 0 Sem informação; 1 Urbana; 2 Rural | Numérico inteiro |
| NACIONALIDADE | 0 SEM INFORMAÇÃO; 1  BRASILEIRO; 2 ESTRANGEIRA; 3  BRASILEIRO NASC EXTERIOR | Numérico inteiro |

| | | |
|---|---|---|
| MUNICIPIO_NASCIMENTO | MUNICÍPIO DE NASCIMENTO | Texto |
| UF_MUN_NASC | UNIDADE FEDERATIVA MUNICÍPIO DE NASCIMENTO | Texto |
| GRAU | CÓDIGO DO TIPO ENSINO | Numérico inteiro |
| CODHAB | CÓDIGO DE HABILITAÇÃO | Numérico inteiro |
| SERIE | SERIAÇÃO DO ALUNO NO GRAU | Numérico inteiro |
| PRONATEC | PARTICIPA DO PROGRAMA PRONATEC 0 = NÃO 1 = SIM | Numérico inteiro |
| FLAG_MOBIL_REDUZ | POSSUI MOBILIDADE REDUZIDA N = NÃO S = SIM | Numérico inteiro |
| TIPO_MOBIL_REDUZ | P = PERMANENTE T = TEMPORÁRIO | Alfanumérico |
| FLAG_CUIDADOR | POSSUI CUIDADOR N = NÃO S = SIM | Alfanumérico |
| TIPO_CUIDADOR | P = PERMANENTE T = TEMPORÁRIO | Alfanumérico |
| FLAG_PROF_SAUDE | POSSUI PROFISSIONAL DA SAÚDE N = NÃO S = SIM | Alfanumérico |

| | | |
|---|---|---|
| TIPO_PROF_SAUDE | PROFISSIONAL DA SAUDE P = PERMANENTE T = TEMPORÁRIO | Alfanumérico |
| ID_AUX_LEI | PRECISA DE PROVA ADAPTADA 0 = NÃO 1 = SIM | Numérico inteiro |
| ID_FONTE | TAMANHO DA FONTE ADAPTADA | Numérico inteiro |
| ID_AUX_TRANS | PRECISA DE PROVA ADAPTADA 0 = NÃO 1 = SIM | Numérico inteiro |
| ID_GUIA_INTERPR | PRECISA DE PROVA ADAPTADA 0 = NÃO 1 = SIM | Numérico inteiro |
| ID_COMP_LEITOR_TELA | PRECISA DE PROVA ADAPTADA 0 = NÃO 1 = SIM | Numérico inteiro |
| ID_INTERPR_LIBRAS | PRECISA DE PROVA ADAPTADA 0 = NÃO 1 = SIM | Numérico inteiro |
| ID_LEI_LAB | PRECISA DE PROVA ADAPTADA 0 = NÃO 1 = SIM | Numérico inteiro |
| ID_PROVA_AMPL | PRECISA DE PROVA ADAPTADA 0 = NÃO 1 = SIM | Numérico inteiro |
| ID_PROVA_BRAILE | PRECISA DE PROVA ADAPTADA 0 = NÃO 1 = SIM | Numérico inteiro |

| | | |
|---|---|---|
| ID_SEM_NECES_REC | PRECISA DE PROVA ADAPTADA 0 = NÃO 1 = SIM | Numérico inteiro |
| ID_VENCE | Participa programa VENCE | Numérico inteiro |
| FLAG_BOLSA_FAM | ALUNO PARTICIPA DO PROGRAMA BOLSA FAMÍLIA 0 = NÃO 1 = SIM | Numérico inteiro |
| DT_MATRIC | DATA MATRÍCULA | Numérico inteiro |
| DTINI_MATRIC | DATA INÍCIO DA MATRÍCULA | Numérico inteiro |
| DTFIM_MATRIC | DATA FIM DA MATRÍCULA | Numérico inteiro |
| FLAG_QUILOMBO | ALUNO DECLARADO QUILOMBOLA 0 = NÃO 1 = SIM | Numérico inteiro |
| FLAG_SIT_ALUNO* | Código de Situação do aluno | Numérico inteiro |
| DTFALEC | DATA DO FALECIMENTO | Numérico inteiro |

# 4. Cronograma e Divisão de Responsabilidades

Bloco 1: Etapas 1 e 2

Etapa 1 - Kick-off, Objetivos e Metas

Meta comum: Alinhar o escopo, entender os limites do dataset e definir as métricas centrais de rendimento (ex.: notas médias, taxas de aprovação/evasão).

- Sabrina Sales: Estrutura inicial do repositório no GitHub (governança de branches, .gitignore, organização das pastas data/, notebooks/, docs/) e setup do ambiente de desenvolvimento.
- Távi Braz: Levantamento do dicionário de dados (tipos de dados, volume, presença de nulos e documentação das variáveis-chave).
- Giovanna Andrade: Redação do documento de escopo, detalhando o problema de negócio/social, objetivos, metas e as perguntas centrais a serem respondidas.

Etapa 2
Definição do Produto Analítico & EDA em Python

Meta comum: Incorporar os feedbacks da Etapa 1 e gerar um panorama completo da evolução do rendimento nos últimos 5 anos por segmento social.

- Sabrina Sales (Pipeline & Séries Temporais):

- Script de ingestão e padronização das bases dos 5 anos.
- Tratamento de missing data, duplicidades e padronização de identificadores geográficos (bairros, zonas ou DREs).
- Análise longitudinal (evolução das médias e taxas globais ano a ano).

- Giovanna Andrade (Segmentação Social e Vulnerabilidade):

- Cruzamento do rendimento por recortes etnográficos (raça/cor). Análise do impacto de programas de assistência social e atendimento PcD no desempenho escolar.
- Identificação formal dos grupos com queda de desempenho ao longo da série histórica.

- Távi Braz - (Proposta Analítica & Insights Qualitativos):

- Formulação da proposta analítica (hipóteses levantadas a partir das distribuições encontradas).
- Investigação superficial dos motivos estruturais/geográficos indicados pelos dados.
- Esboço das primeiras recomendações práticas e pedagógicas baseadas nas evidências.

Bloco 2: Etapas 3 e 4

Etapa 3
Apresentação de Produtos & Data Storytelling

Meta comum: Incorporar os feedbacks da Etapa 2 e transformar os achados em uma narrativa coerente voltada para tomada de decisão.

- Sabrina Sales (Visualização Técnica & Repositório):
- Geração de gráficos limpos e padronizados (paleta de cores acessível, títulos claros e anotações explicativas).
- Limpeza final dos notebooks com comentários e documentação do código.

- Távi Braz (Storyline dos Dados & Validação Estatística):

- Construção da linha lógica da análise: Cenário Geral \rightarrow Disparidades Sociais/Geográficas \rightarrow Grupos Críticos \rightarrow Fatores Correlacionados.
- Validação para garantir que os dados suportem com precisão as afirmações feitas na narrativa.

- Giovanna Andrade (Estruturação Textual & Roteiro):

- Redação da minuta do relatório final, costurando contextualização, análise e recomendações para mitigação das desigualdades.
- Estruturação do roteiro narrativo da apresentação (slides com foco em visualização sem poluição textual).

Etapa 4
Encerramento, Documentação e Entregáveis Finais

Meta comum: Revisão geral, incorporação dos feedbacks da Etapa 3 e ensaio conjunto para a gravação.

- Sabrina Sales (GitHub & Entrega Técnica):
- Finalização do repositório no GitHub com README.md completo e intuitivo (guia de reprodução do código, requisitos e resumo das conclusões).

- Checagem técnica dos artefatos e arquivos entregáveis.

- Távi Braz (Relatório Final & Apoio Visual):
    - Diagramação e consolidação final do relatório analítico em PDF/documento.
    - Preparação dos slides finais para o vídeo de apresentação.

- Giovanna Andrade (Coordenação do Vídeo & Conclusões):

- Consolidação do roteiro final do vídeo de apresentação (distribuindo falas de 2 a 3 minutos para cada membro).
- Gravação/edição final do vídeo e checagem de conformidade com todos os critérios de avaliação da disciplina.

# 5. Bibliografia

**Github: https://github.com/Hrolfr/Mackenzie_ProjetoAplicadoI_2semestre.git**